Устойчивость рекомендаций HSTU: проверка причин чувствительности к последнему фильму

В первом эксперименте изменение последнего фильма существенно меняло рекомендации HSTU. На этом этапе проверяется, насколько наблюдаемый эффект связан с маскированием просмотренных фильмов и временными метками. Дополнительно исследуется чувствительность каждой из последних десяти позиций.

Общие сведения и проверка корректности удаления

Условия эксперимента

Используются те же данные MovieLens 1M, сохранённые параметры HSTU (epoch_097.ckpt), первые 500 пользователей test-набора и базовый seed 42, что и на первом этапе.

Метрики остаются прежними: Top-10 overlap, JS divergence и Top-1 changed.

Проверка корректности возмущений

В эксперименте сохраняются архитектура, обученные параметры и логика вычислений модели. Все возмущения реализованы только через изменение входных данных.

При замене изменяется только идентификатор выбранного фильма. При удалении согласованно удаляются фильм и его временная метка, последующие элементы сдвигаются влево, фактическая длина уменьшается на единицу, а свободные позиции заполняются нулями. При изменении времени корректируется только временная метка с сохранением порядка событий.

Модель изначально поддерживает истории разной длины в пределах настроенного максимума. Например, история A → B передаётся как A, B, 0, …, 0 вместе с фактической длиной 2. Обработка padding нулевого дополнения предусмотрена в архитектуре самой модели: представления неиспользуемых позиций обнуляются, а переданная длина определяет реальную часть истории и выбор последнего состояния для предсказания. Поэтому после каждого возмущения достаточно согласованно сформировать вход и заново вызвать стандартную процедуру получения рекомендаций.

1. Влияние маскирования просмотренных фильмов

Перед выдачей рекомендаций мы исключаем фильмы, которые уже есть в истории пользователя. Если удалить или заменить фильм в истории, может измениться и список исключённых фильмов. Поэтому рекомендации могут измениться по двум причинам: модель получила другую историю, а некоторые фильмы стали доступны для рекомендации или, наоборот, были исключены. Чтобы разделить эти эффекты, сравниваем два варианта маскирования: динамический и фиксированный.

Рассмотрим замену последнего фильма:

```
Исходная история:   A → B → C
Изменённая история: A → B → D
```

Динамическая маска строится по текущей истории. Для исходной истории исключены A, B, C, для изменённой - A, B, D. После замены фильм C становится допустимым, а D исключается.

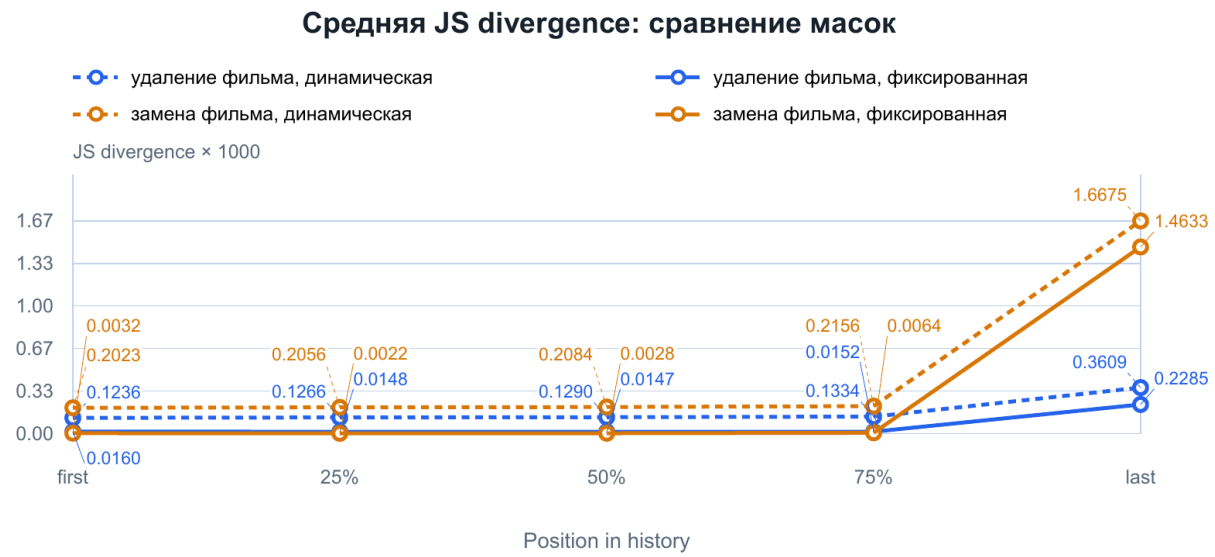
Фиксированная маска строится по исходной истории и применяется к обеим историям. В обоих случаях исключены A, B, C. Поэтому множество допустимых рекомендаций сохраняется, хотя вход модели изменился.

При удалении действует то же правило: динамическая маска разрешает удалённый фильм, если он больше не встречается в истории, а фиксированная продолжает его исключать.

Результаты



Top-10 overlap: динамическая и фиксированная маски



JS divergence: динамическая и фиксированная маски



Top-1 changed: динамическая и фиксированная маски

Изменение последнего фильма

Изменение	Маска	Top-10 overlap	JS × 1000	Top-1 changed, %
Удаление	Динамическая	0.5112	0.3609	73.60
Удаление	Фиксированная	0.5222	0.2285	70.60
Замена	Динамическая	0.2493	1.6675	89.20
Замена	Фиксированная	0.2506	1.4633	89.08

Вывод

При фиксированной маске Top-10 overlap немного увеличивается, а доля смен первой рекомендации и JS divergence уменьшаются. Динамическая маска изменяет множество допустимых кандидатов, поэтому часть различий в выдаче возникает из-за разрешения и исключения фильмов. Однако сильная чувствительность к последнему фильму сохраняется: при его замене с фиксированной маской общими остаются около 25% рекомендаций, а первая рекомендация меняется примерно в 89% случаев.

2. Влияние временных меток

Сравним, как меняются рекомендации в трёх случаях: при замене фильма, удалении фильма из истории и изменении только времени его просмотра.

Рассмотрим историю A → B → C, где фильмы просмотрены в 10:00, 11:00 и 12:00 соответственно.

- **Замена фильма:** (C, 12:00) заменяется на (D, 12:00). Время сохраняется.

- **Удаление фильма:** пара (C, 12:00) удаляется целиком; история становится короче.

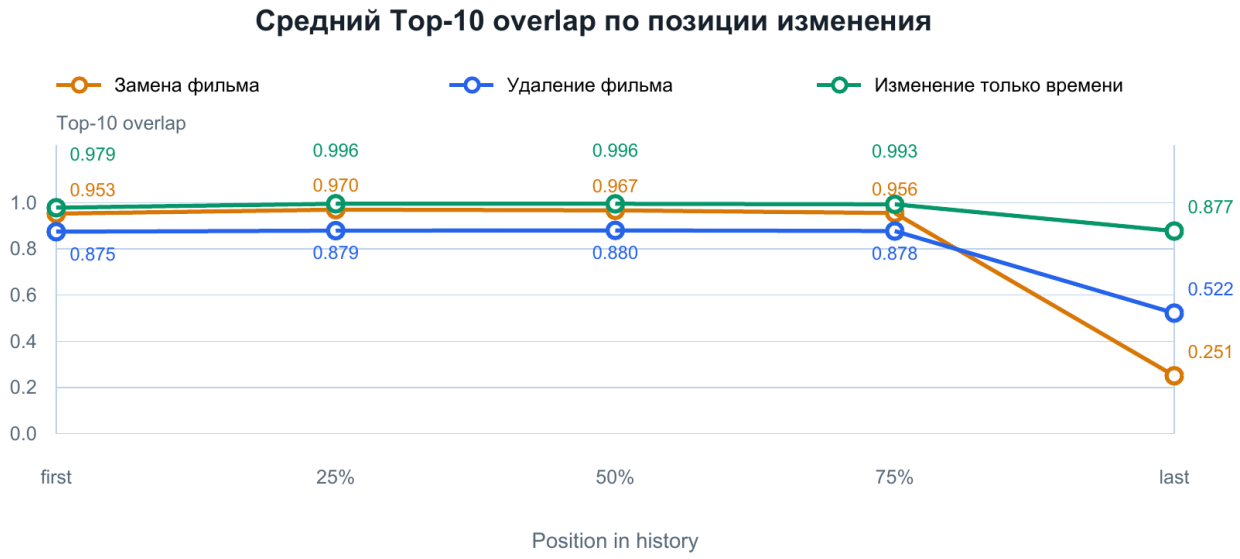
- **Изменение только времени:** фильм C сохраняется, а его временная метка сдвигается.

Для времени используются шесть заданных сдвигов: ±1 час, ±1 день и ±7 дней. Для каждого пользователя и позиции сначала считаются метрики при каждом сдвиге, затем эти шесть значений усредняются. Полученное среднее усредняется по 500 пользователям.

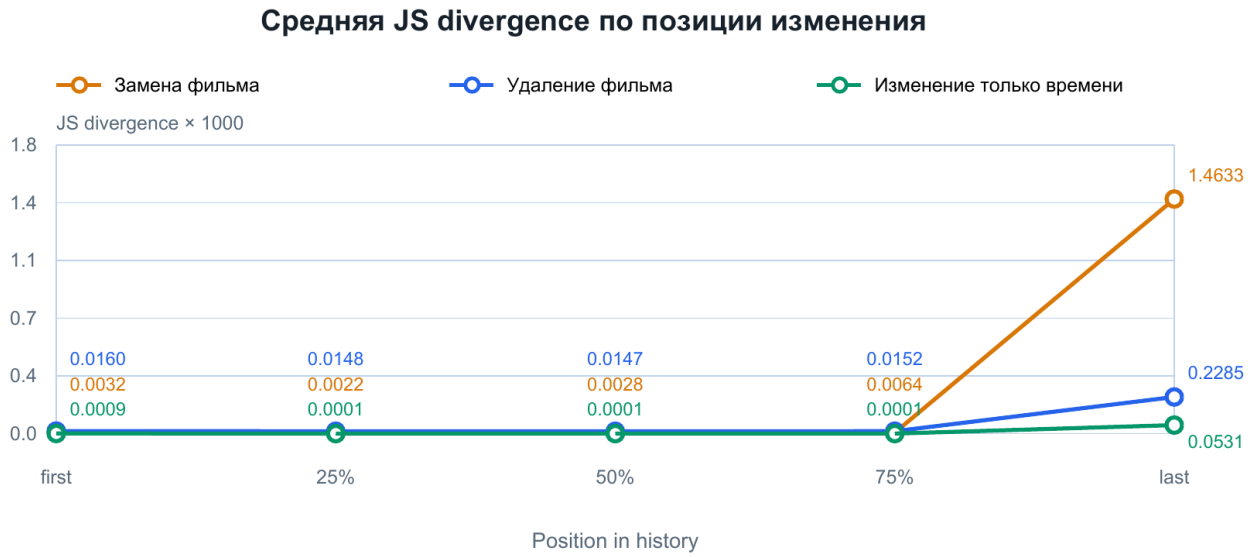
Временная метка ограничивается соседними событиями, чтобы сохранить порядок просмотров; для последнего элемента верхняя граница - время правильного следующего фильма. Поэтому фактический сдвиг может быть меньше заданного или нулевым. Все такие случаи включены в среднее.

Во всех трёх вариантах используется фиксированная маска исходной истории. Графики показывают средние значения метрик для пяти исходных позиций.

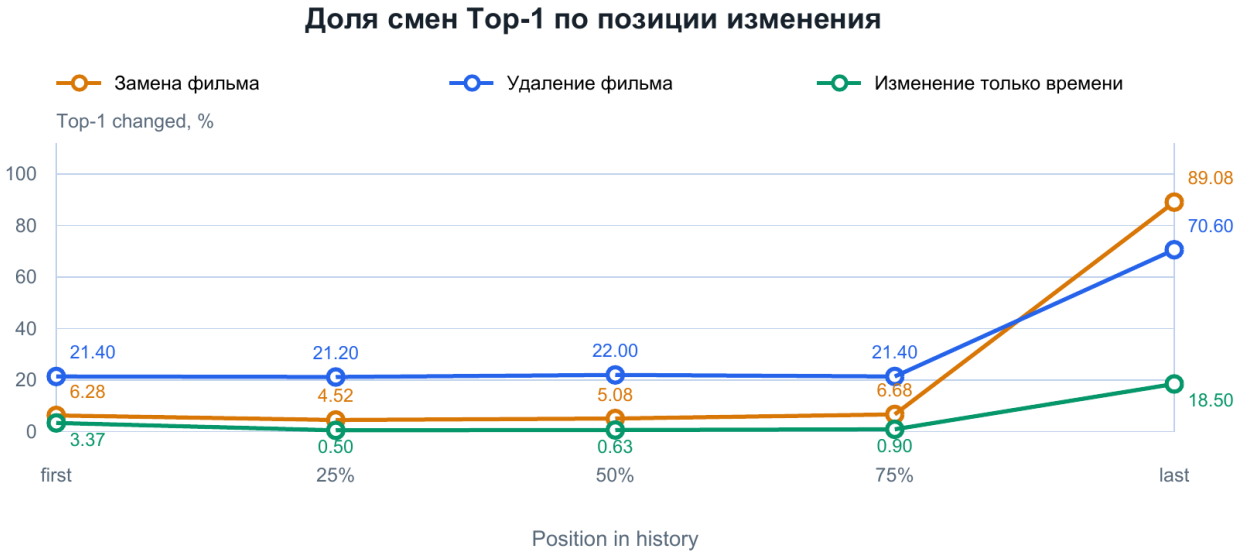
Сравнение трёх изменений



Top-10 overlap: замена фильма, удаление и среднее изменение времени



JS divergence: три вида изменения; значения умножены на 1000



Top-1 changed: три вида изменения, %

Изменение последнего просмотра

Воздействие	Top-10 overlap	JS × 1000	Top-1 changed, %
Замена фильма	0.2506	1.4633	89.08
Удаление фильма	0.5222	0.2285	70.60
Изменение времени	0.8774	0.0531	18.50

Вывод

Изменение только времени в выбранном наборе сдвигов оказывает меньший средний эффект, чем замена фильма или удаление просмотра. Для последней позиции сохраняется около 88% Top-10, а первая рекомендация меняется в 18.5% случаев. Замена фильма даёт самый сильный эффект, удаление занимает промежуточное положение.

3. Чувствительность последних десяти позиций

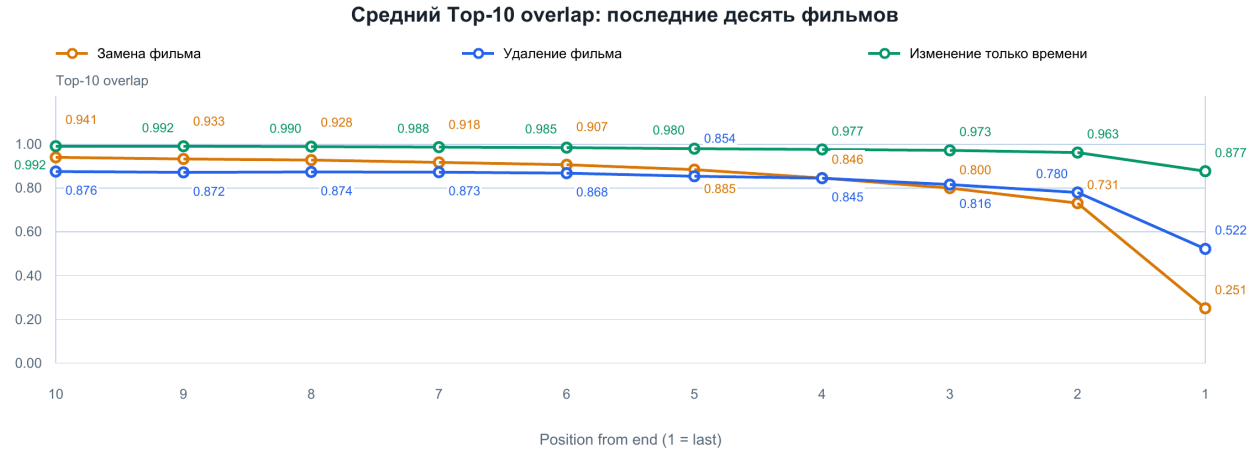
Чтобы подробнее изучить чувствительность модели в конце истории, поочерёдно изменяем каждый из последних десяти просмотров. Каждый раз берём исходную историю и изменяем только один просмотр. Позиции отсчитываются от конца: 1 — последний фильм, 2 — предпоследний, 10 — десятый от конца.

Для каждой позиции сравниваем три варианта: замену фильма с сохранением времени, удаление фильма вместе с его временной меткой и изменение только времени просмотра.

На графиках показаны средние значения метрик. Под каждым графиком приведена таблица: для каждой позиции жирным указано среднее по 500 пользователям, а под ним — границы 95%-го доверительного интервала в формате [нижняя граница; верхняя граница].

Интервалы рассчитаны методом bootstrap: из исходных 500 пользователей случайно выбирали 500 с возможностью повторения и заново вычисляли среднее. Эту процедуру повторили 5000 раз. Нижняя и верхняя границы интервала охватывают центральные 95% полученных средних.

Top-10 overlap

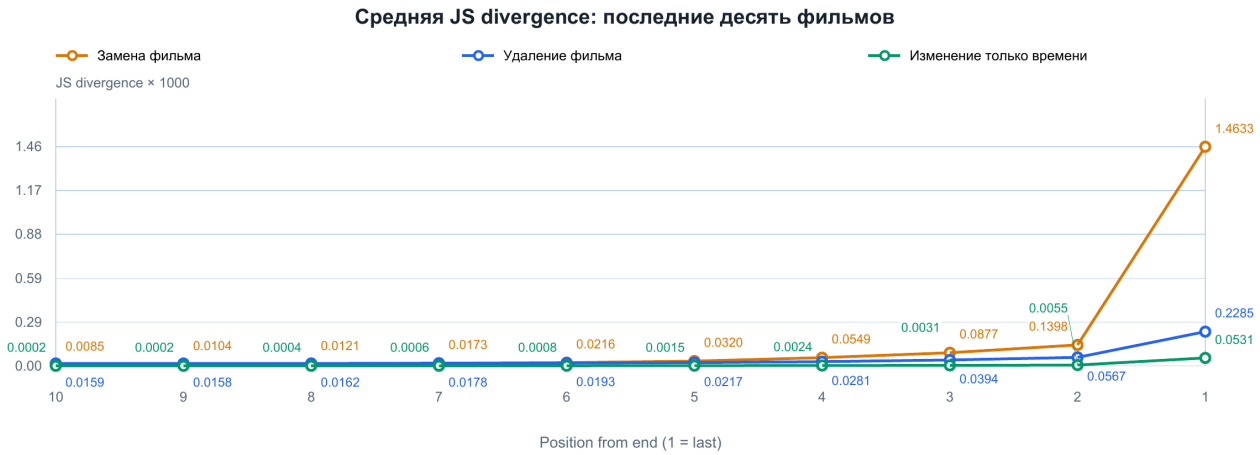


Top-10 overlap для последних десяти позиций

Таблица 1. Top-10 overlap: средние и 95%-е доверительные интервалы.

Позиция от конца	Замена фильма	Удаление фильма	Только время
10	**0.9407** [0.9357; 0.9458]	**0.8760** [0.8662; 0.8858]	**0.9917** [0.9898; 0.9935]
9	**0.9334** [0.9284; 0.9386]	**0.8722** [0.8622; 0.8824]	**0.9916** [0.9895; 0.9935]
8	**0.9284** [0.9224; 0.9341]	**0.8740** [0.8640; 0.8840]	**0.9899** [0.9876; 0.9919]
7	**0.9178** [0.9117; 0.9236]	**0.8730** [0.8630; 0.8832]	**0.9875** [0.9850; 0.9900]
6	**0.9069** [0.9005; 0.9134]	**0.8684** [0.8582; 0.8786]	**0.9852** [0.9827; 0.9877]
5	**0.8846** [0.8774; 0.8915]	**0.8544** [0.8436; 0.8646]	**0.9804** [0.9767; 0.9837]
4	**0.8461** [0.8364; 0.8550]	**0.8454** [0.8344; 0.8562]	**0.9769** [0.9732; 0.9804]
3	**0.8002** [0.7888; 0.8113]	**0.8164** [0.8040; 0.8288]	**0.9727** [0.9689; 0.9763]
2	**0.7314** [0.7176; 0.7447]	**0.7802** [0.7664; 0.7940]	**0.9627** [0.9574; 0.9677]
1	**0.2506** [0.2369; 0.2646]	**0.5222** [0.4994; 0.5444]	**0.8774** [0.8648; 0.8902]

JS divergence



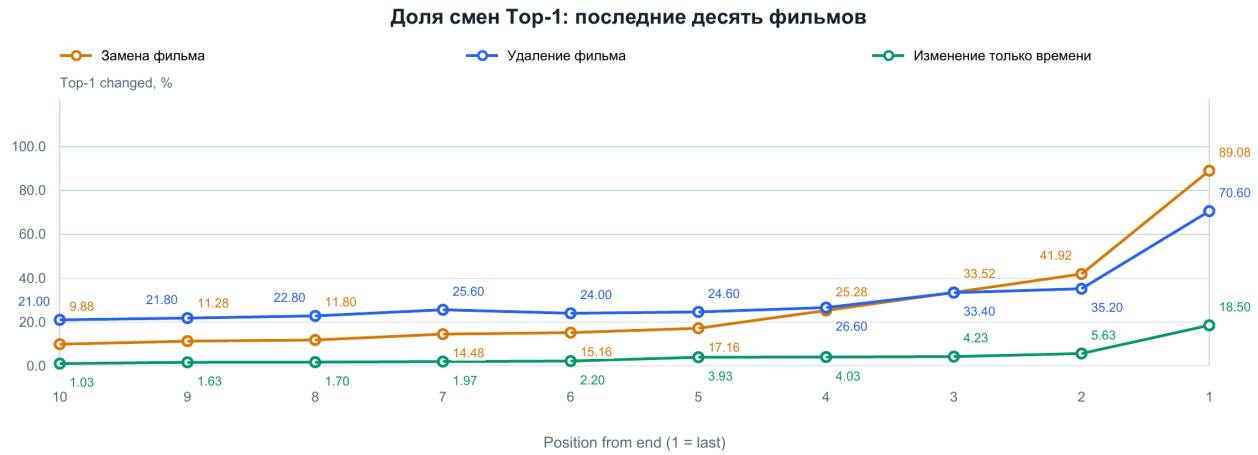
JS divergence для последних десяти позиций; значения умножены на 1000

И средние, и границы интервалов в таблице умножены на 1000.

Таблица 2. JS × 1000: средние и 95%-е доверительные интервалы.

Позиция от конца	Замена фильма	Удаление фильма	Только время
10	**0.008542** [0.007493; 0.009688]	**0.015924** [0.014578; 0.017331]	**0.000223** [0.000157; 0.000305]
9	**0.010380** [0.009287; 0.011529]	**0.015844** [0.014485; 0.017253]	**0.000223** [0.000170; 0.000285]
8	**0.012101** [0.010808; 0.013450]	**0.016168** [0.014836; 0.017556]	**0.000425** [0.000298; 0.000595]
7	**0.017317** [0.015245; 0.019534]	**0.017794** [0.016247; 0.019469]	**0.000631** [0.000411; 0.000931]
6	**0.021587** [0.018472; 0.026074]	**0.019263** [0.017367; 0.021525]	**0.000802** [0.000574; 0.001075]
5	**0.031964** [0.028480; 0.035967]	**0.021748** [0.020128; 0.023407]	**0.001480** [0.001111; 0.001879]
4	**0.054861** [0.048906; 0.061528]	**0.028078** [0.025511; 0.030984]	**0.002438** [0.001958; 0.002975]
3	**0.087688** [0.079496; 0.096774]	**0.039352** [0.035574; 0.043474]	**0.003131** [0.002475; 0.003849]
2	**0.139841** [0.129341; 0.151501]	**0.056690** [0.051668; 0.062068]	**0.005529** [0.004493; 0.006662]
1	**1.463314** [1.358705; 1.570586]	**0.228489** [0.209371; 0.248065]	**0.053143** [0.044598; 0.061869]

Top-1 changed



Top-1 changed для последних десяти позиций, %

И средние, и границы интервалов в таблице указаны в процентах.

Таблица 3. Top-1 changed, %: средние и 95%-е доверительные интервалы.

Позиция от конца	Замена фильма	Удаление фильма	Только время
10	**9.88** [8.04; 11.84]	**21.00** [17.60; 24.60]	**1.03** [0.40; 1.83]
9	**11.28** [9.28; 13.36]	**21.80** [18.40; 25.60]	**1.63** [0.83; 2.60]
8	**11.80** [9.80; 13.92]	**22.80** [19.20; 26.60]	**1.70** [1.00; 2.60]
7	**14.48** [12.24; 16.88]	**25.60** [21.80; 29.40]	**1.97** [1.17; 2.87]
6	**15.16** [12.92; 17.48]	**24.00** [20.40; 27.80]	**2.20** [1.30; 3.20]
5	**17.16** [14.68; 19.68]	**24.60** [21.00; 28.40]	**3.93** [2.73; 5.23]
4	**25.28** [22.44; 28.04]	**26.60** [22.80; 30.40]	**4.03** [2.90; 5.20]
3	**33.52** [30.48; 36.68]	**33.40** [29.20; 37.60]	**4.23** [3.07; 5.50]
2	**41.92** [38.68; 45.16]	**35.20** [31.00; 39.40]	**5.63** [4.30; 7.03]
1	**89.08** [87.40; 90.68]	**70.60** [66.40; 74.60]	**18.50** [16.13; 20.87]

Вывод

Изменение последнего фильма влияет на рекомендации заметно сильнее, чем изменение предпоследнего. При замене фильма Top-10 overlap снижается с 0.7314 для предпоследней позиции до 0.2506 для последней. При удалении — с 0.7802 до 0.5222. Это означает, что после изменения последнего фильма в рекомендациях сохраняется значительно меньше фильмов из исходного Top-10. Также увеличивается JS divergence и чаще меняется первая рекомендация.

Общий вывод

Сильная чувствительность к последнему фильму сохраняется при фиксированном множестве кандидатов и неизменных временных метках. Изменение маски влияет на метрики, но не устраняет наблюдаемый эффект. Выбранные временные возмущения в среднем дают меньший эффект, а между предпоследней и последней позициями ярко выражен скачок метрик.